

Implementación de agentes de IA para Esnupitos GO

Integrantes: Camila Hernandez

Profesor: Javier Peña

Asignatura: Ingeniería de soluciones con inteligencia artificial

Fecha de entrega: 11-04-2026

Análisis del caso organizacional

El emprendimiento Esnupitos GO se dedica a la importación de productos desde Asia hacia Chile, principalmente artículos de colección del rubro K-POP, actuando como intermediario entre clientes y proveedores internacionales.

El proceso de negocio incluye la compra de productos, su envío a una casilla en el país de origen y posteriormente la gestión de transporte internacional hacia Chile, considerando costos asociados como envío y aduanas.

A partir del análisis del funcionamiento del GO, se identifican múltiples consultas recurrentes por parte de los clientes, principalmente relacionadas con:

- Estado de los pedidos
- Costos de envío y aduana
- Tiempos de entrega
- Condiciones del servicio

Estas consultas son gestionadas manualmente por una única persona, lo que genera tiempos de respuesta elevados, sobrecarga operativa y posibles inconsistencias en la información entregada.

En este contexto, surge la necesidad de implementar una solución que permita automatizar la atención al cliente, garantizando respuestas rápidas, precisas y coherentes con la información del negocio.

Para ello, se propone el desarrollo de un asistente inteligente basado en modelos de lenguaje (LLM) combinado con técnicas de recuperación aumentada (RAG), que permita utilizar datos internos del sistema para enriquecer las respuestas y mejorar su confiabilidad.

Esta solución busca optimizar la gestión del emprendimiento, reducir la carga de trabajo manual y mejorar la experiencia del cliente mediante un sistema automatizado de atención.

Formulación de prompts

El prompt ha sido diseñado para controlar el comportamiento del modelo de lenguaje dentro del contexto del emprendimiento Esnupitos GO.

Se incorporan instrucciones específicas que permiten:

- Restringir la generación de información únicamente al contexto proporcionado, lo que es fundamental en arquitecturas RAG
- Evitar la generación de contenido incorrecto mediante la regla explícita de no inventar información
- Mantener un lenguaje claro y accesible para usuarios no técnicos
- Priorizar las consultas más relevantes del negocio, como estado de pedidos, costos y tiempos de entrega

Además, el uso de variables como {question} y {context} permite integrar dinámicamente la información recuperada desde las fuentes de datos, mejorando la precisión y coherencia de las respuestas.

Este enfoque contribuye a reducir las alucinaciones del modelo y a aumentar la confiabilidad del sistema. Adicionalmente, se implementa un enfoque de interacción guiada mediante opciones predefinidas, lo que permite acotar el tipo de consultas realizadas por los usuarios. Esto contribuye a mejorar la precisión de las respuestas, reducir ambigüedades y facilitar la recuperación de información relevante dentro del sistema RAG.

Eres un asistente virtual del emprendimiento Esnupitos GO.

Tu función es responder consultas de clientes basándote únicamente en la información entregada en el contexto.

El usuario seleccionará una opción del sistema, y debes limitar tu respuesta SOLO a esa categoría.

Opciones disponibles:

- Estado de pedido
- Costos de envío
- Tiempos de entrega
- Preguntas frecuentes

Instrucciones:

- Responde únicamente en función de la opción seleccionada.
- No mezcles información de otras categorías.
- No inventes información.
- Usa solo el contexto proporcionado.
- Mantén un lenguaje claro, breve y amigable.
- Si no existe información suficiente en el contexto, responde: "No dispongo de esa información en este momento."

Datos de entrada:

Opción seleccionada: {option}

Pregunta del cliente: {question}

Contexto:

{context}

Diseño e implementación de pipeline RAG

El sistema propuesto utiliza un enfoque de Recuperación Aumentada por Generación (RAG), el cual permite mejorar la calidad de las respuestas mediante la integración de datos reales del GO.

El funcionamiento del sistema se basa en un flujo de procesamiento estructurado, donde se combinan etapas de recuperación de información y generación de respuestas.

En primer lugar, el usuario interactúa con el sistema mediante la selección de una opción. A partir de esta entrada, el sistema identifica el tipo de información requerida.

Posteriormente y dependiendo de la opción escogida se realiza una búsqueda en las fuentes de datos internas del GO, tales como registros de pedidos, costos de envío, tiempos de entrega y preguntas frecuentes. Esta etapa corresponde al proceso de recuperación de información.

Es muy importante separar las opciones para entregar una respuesta adecuada ya que si el cliente consulta por el estado de un pedido, se debe abrir la opción para que ponga el número del pedido y buscar específicamente ese pedido en la base de datos.

Una vez obtenidos los datos relevantes, estos se estructuran como contexto y se envían junto con la consulta del usuario al modelo de lenguaje.

Finalmente, el modelo genera una respuesta utilizando exclusivamente la información proporcionada, lo que permite asegurar mayor precisión, coherencia y confiabilidad en los resultados entregados.

El uso de RAG permite reducir significativamente el riesgo de generación de información incorrecta (alucinaciones), ya que las respuestas se basan en datos reales del sistema. De esta forma, se fortalece la coherencia entre la información disponible y las respuestas entregadas al usuario, aumentando la credibilidad de la solución.

Arquitectura

La arquitectura de la solución propuesta se basa en un sistema modular que integra componentes de interacción, procesamiento y generación de respuestas.

En primer lugar, el usuario interactúa con el sistema a través de una interfaz de consola, donde selecciona una opción y realiza su consulta.


Posteriormente, la solicitud es procesada por un módulo backend desarrollado en Python, el cual se encarga de interpretar la entrada del usuario y estructurar la consulta.

Luego, el sistema accede a las fuentes de datos internas del GO, específicamente un archivo de texto que contiene información relevante del negocio. Estos datos son utilizados como contexto dentro del pipeline RAG.

A continuación, se construye un prompt estructurado que incluye la consulta del usuario, la opción seleccionada y el contexto recuperado.

Finalmente, este prompt es enviado a un modelo de lenguaje (LLM), el cual genera una respuesta basada en la información proporcionada.

La arquitectura permite una integración eficiente entre los componentes, asegurando coherencia en las respuestas y facilitando la escalabilidad del sistema.



Documentación técnica

Se optó por una implementación simple utilizando Python, debido a su facilidad de integración con APIs de modelos de lenguaje.

El uso de un archivo de texto como fuente de datos permite una solución liviana y fácilmente modificable, adecuada para un emprendimiento de pequeña escala.

Se decidió utilizar un enfoque RAG en lugar de un modelo puramente generativo, con el fin de reducir errores y asegurar que las respuestas están basadas en información real del negocio.

Además, se implementó un sistema de opciones predefinidas para guiar al usuario, lo que permite mejorar la precisión de las consultas y reducir ambigüedades.

El sistema depende del acceso a la API de OpenAI, lo que puede generar limitaciones en caso de falta de conectividad o restricciones de uso. La base de datos utilizada es estática, por lo que no refleja cambios en tiempo real. El modelo puede presentar errores si el contexto entregado es insuficiente o ambiguo.

Conclusión

Para finalizar, se concluye que la implementación de un agente de inteligencia artificial en el emprendimiento Esnupitos GO representa una solución efectiva para optimizar la gestión de atención al cliente, especialmente en contextos donde existe una alta carga de consultas repetitivas y recursos limitados.

El uso de un enfoque basado en RAG permite mejorar significativamente la calidad de las respuestas entregadas, ya que estas se fundamentan en información real del sistema. Esto reduce considerablemente el riesgo de generación de contenido incorrecto o inconsistente, aumentando la confiabilidad del sistema y asegurando que los usuarios reciban información clara y precisa.

Asimismo, la automatización de respuestas contribuye a disminuir la carga operativa del emprendimiento, optimizar los tiempos de atención y mejorar la experiencia del cliente, lo que resulta clave para la eficiencia y escalabilidad del negocio. La incorporación de un sistema guiado por opciones también permite estructurar mejor las consultas, facilitando la recuperación de información relevante.

Por otra parte, este proyecto permitió aplicar conceptos teóricos de inteligencia artificial en un caso práctico real, fortaleciendo la comprensión del uso de modelos de lenguaje y arquitecturas RAG en soluciones concretas. Esto demuestra el potencial de estas tecnologías para ser implementadas en emprendimientos de pequeña escala.

Como proyección futura, se propone integrar una base de datos dinámica, mejorar la interfaz de usuario mediante una aplicación web y ampliar las funcionalidades del sistema, lo que permitiría una mayor automatización y una mejor experiencia para los usuarios.

El uso de herramientas de inteligencia artificial como ChatGPT se utilizó únicamente como apoyo en la redacción y organización del contenido, no como fuente principal de información.